ESTADO DEL ARTE

Clasificación de núcleos celulares en imágenes histológicas mediante Deep Learning

Andrés Duarte Chaves
Maestría en Ingeniería Biomédica · Universidad del Norte
Entregable 1 · Avance para revisión docente · 6 de noviembre de 2026

Alcance: revisión narrativa preliminar con fuentes verificadas. No constituye todavía la revisión trazable completa exigida en la sección 3 del entregable. La búsqueda en WoS/Scopus/IEEE, el flujo PRISMA y la selección definitiva de tres modelos permanecen pendientes.

1. Problema y pregunta de investigación

El proyecto aborda clasificación supervisada de recortes RGB de núcleos del conjunto NuCLS. Se consideran tres etiquetas: tumor no mitótico, linfocito y estromal no TIL/no macrófago. La entrada es un recorte de 128 × 128 píxeles centrado en un núcleo anotado; la salida es una distribución de probabilidad sobre las tres clases. No se pretende identificar telocitos ni localizar automáticamente núcleos en una imagen completa.

Pregunta: ¿qué desempeño y variabilidad pueden alcanzar modelos básicos de Deep Learning al clasificar estas tres categorías, bajo un protocolo común y con separación de pacientes entre entrenamiento y validación?

2. Evolución de la evidencia

Aprendizaje de características locales. Sirinukunwattana et al. [1] estudiaron detección y clasificación nuclear en histología de colon mediante redes convolucionales y aprovechamiento del contexto vecinal. Este antecedente respalda estudiar representaciones aprendidas de la morfología nuclear. No justifica, por sí solo, cualquier CNN pequeña ni demuestra frecuencia de uso de nuestra implementación.

Modelos conjuntos. HoVer-Net [2] combina segmentación de instancias y clasificación. Utiliza distancias horizontales y verticales respecto al centro nuclear para separar estructuras próximas. Es un antecedente de tareas integradas; compararlo directamente con un clasificador que recibe núcleos previamente localizados puede favorecer a este último por diferencias en la dificultad de entrada.

Datos y calidad de las anotaciones. NuCLS [3] aporta anotaciones de cáncer de mama producidas con participación de estudiantes y patólogos, controles de calidad y análisis multievaluador. Sus más de 220.000 anotaciones no equivalen a ese número de pacientes ni necesariamente a núcleos únicos. El desacuerdo entre evaluadores y las clases menos frecuentes deben formar parte de la interpretación de los resultados.

3. Tendencias recientes y comparación crítica

Sánchez-Torres et al. [4] compararon métodos clásicos con ResNet50 y un vision transformer en PanNuke. Su trabajo diferencia núcleos aislados y contexto circundante. Esta separación es pertinente para nuestro diseño: el contexto del recorte constituye una decisión experimental, no un detalle neutro. SENUCLS [5], por su parte, incorpora relaciones entre núcleos mediante grafos y características de forma. Representa una alternativa contextual que requiere máscaras de instancia y un pipeline diferente.

Estos antecedentes muestran varias rutas de investigación: aprender características locales, integrar segmentación y clasificación, y modelar relaciones espaciales. No permiten afirmar que una familia sea universalmente superior. El dataset, las etiquetas, la disponibilidad previa de la localización nuclear y el protocolo de evaluación condicionan la comparación.

4. Matriz inicial de evidencia

Referencia / problema / datos	Modelos y función en el estudio	Resultados verificados y límite
[1] Sirinukunwattana et al., 2016. Detección y clasificación; histología de colon.	CNN con restricciones espaciales para detección; clasificación convolucional con contexto. Antecedente metodológico.	No se transcriben cifras: extracción de tablas y configuraciones comparativas pendiente. Resumen consultado.
[2] Graham et al., 2019. Segmentación y clasificación; múltiples datasets histológicos.	HoVer-Net, modelo multirrama propuesto. No es un clasificador simple de recortes.	Artículo reporta comparaciones multitarea. Valores específicos no extraídos en esta revisión; no se usa para un ranking numérico.
[3] Amgad et al., 2022. Anotación, clasificación y segmentación; NuCLS mamario.	Mask R-CNN en el proceso de sugerencias. Estudio central para procedencia y calidad de datos.	Más de 220.000 anotaciones. Esta cifra describe el recurso, no el desempeño de nuestro clasificador. Métricas de acuerdo y clasificación requieren extracción por condición.
[4] Sánchez-Torres et al., 2026. Clasificación de núcleos; PanNuke.	Comparación de modelos clásicos, ResNet50 y ViT. Relevancia directa para clasificación aislada.	Tabla 14: ResNet50, F1 (%) neoplásico 82,90; conectivo 71,49; inflamatorio 71,98; epitelial 71,49; muerto 51,66. Sin dispersión en esa tabla. No son resultados NuCLS.
[5] SENUCLS. Clasificación nuclear; implementación oficial.	GNN con estructura entre núcleos y representación de su forma. Método propuesto.	Código y descripción metodológica consultados. Datos, resultados y DOI del artículo pendientes de extracción; no se contabiliza como baseline básico.

Lectura crítica: no se reutilizan cifras de un dataset como meta numérica de otro, ni se equipara F1 por clase con macro-F1. La presencia de una arquitectura como método propuesto o backbone tampoco demuestra que sea un baseline recurrente.

5. Tres candidatos del piloto: fundamento y límites

El piloto en curso utiliza tres candidatos con igual protocolo y cinco semillas por modelo. Esta elección es exploratoria: la tabla de frecuencia bibliográfica aún no permite declararlos los tres baselines definitivos. No se ajustará retrospectivamente la búsqueda para favorecerlos.

Candidato / parámetros propios	Fundamento técnico	Estado de la evidencia
CNN local 93.635 parámetros	Convoluciones 3×3 (32, 64 y 128 canales), ReLU, pooling, promedio global, dropout y salida de 3 clases. Sesgo de localidad y pesos compartidos.	Implementación propia; [1] apoya la familia, no esta arquitectura exacta. Configuración bibliográfica específica pendiente.
ResNet18 11.178.051 parámetros	Bloques residuales: y = F(x) + x; facilitan optimización de representaciones más profundas [6]. Salida adaptada a 3 clases.	La evidencia directa [4] corresponde a ResNet50. No demuestra frecuencia de ResNet18 para nuestra tarea.
MobileNetV2 2.227.715 parámetros	Convoluciones separables en profundidad, residuales invertidos y cuellos de botella lineales [7]. Explora coste computacional reducido.	[7] fundamenta arquitectura general; no prueba uso frecuente como baseline de clasificación nuclear. Candidato especialmente provisional.

Los parámetros anteriores proceden de nuestras implementaciones con tres salidas, no de una extracción de los artículos. Todos los candidatos emplean softmax y entropía cruzada; en el piloto se entrenan desde cero con Adam. Un esquema compacto es: recorte RGB → representación convolucional → agregación espacial → tres probabilidades.

6. Justificación comparativa y vacío operativo

El papel esperado de estos modelos es establecer un nivel de referencia antes de incorporar arquitecturas más complejas. Su analogía con una regresión logística es funcional: servir como comparación inicial reproducible. No son equivalentes en capacidad, linealidad ni número de parámetros; esa diferencia debe discutirse, especialmente para ResNet18.

El aporte propuesto es construir una comparación controlada para la selección concreta de clases y recortes NuCLS, con separación por paciente, evaluación por clase, variabilidad entre semillas y coste computacional. Esto es una necesidad de nuestro experimento, no una afirmación de que toda la literatura carezca de esas prácticas.

Nuestra preparación contiene 14.428 recortes de entrenamiento de 79 pacientes y 3.571 de validación de 19 pacientes. El filtrado de recortes sin padding introduce selección hacia núcleos interiores. Las imágenes del mismo paciente son dependientes; las semillas describen variabilidad del entrenamiento, no nuevos pacientes. El piloto continúa y no se incorporan métricas parciales como resultados definitivos.

7. Estrategia reproducible y trabajo pendiente

Consulta realizada para este avance: verificación dirigida de registros en PubMed, página editorial de Wiley, arXiv y repositorio oficial SENUCLS, el 6 de noviembre de 2026. El corpus de este documento reúne cuatro artículos de aplicación [1–4], una implementación oficial [5] y dos artículos de arquitectura general [6–7]. Es un corpus seleccionado, no el resultado de un cribado exhaustivo.

Búsqueda propuesta: periodo 2018–2026, conservando trabajos fundacionales anteriores como contexto. Bases: WoS, Scopus e IEEE Xplore; arXiv complementario. Cadena base a adaptar a los campos de cada plataforma:

(“nucleus classification” OR “nuclei classification” OR “cell type classification”) AND (histopatholog* OR histolog*) AND (“deep learning” OR CNN OR “convolutional neural network”) AND (baseline OR compar*)

Incluir: clasificación nuclear histológica, modelos DL comparativos identificables, arquitectura y protocolo suficientemente descritos, métricas verificables. **Separar como contexto:** segmentación/detección sin evaluación de clasificación comparable, clasificación de imágenes completas, tinciones u objetivos diferentes. **Excluir del conteo:** duplicados y modelos sin especificación reproducible.

Frecuencia: aún no calculada. Debe contar estudios únicos que utilicen cada arquitectura exacta como referencia; no mezclar variantes de ResNet ni convertir backbones en clasificadores independientes. **PRISMA:** pendientes exportaciones y conteos por base; no se presentan números inventados. Registrar selección, exclusiones, responsable y eventual revisión adicional.

Calidad: para cada artículo se verificará independencia por paciente, prevención de fuga, repeticiones, dispersión, pruebas estadísticas y presupuesto de comparación. No se asignan puntuaciones definitivas basándose únicamente en resúmenes. Tampoco se atribuyen cuartiles sin verificar fuente y año.

8. Referencias verificadas

[1] Sirinukunwattana K, et al. Locality Sensitive Deep Learning for Detection and Classification of Nuclei in Routine Colon Cancer Histology Images. IEEE Trans Med Imaging. 2016;35(5):1196–1206. Enlace.

[2] Graham S, et al. HoVer-Net: Simultaneous segmentation and classification of nuclei in multi-tissue histology images. Medical Image Analysis. 2019;58:101563. Enlace.

[3] Amgad M, et al. NuCLS: A scalable crowdsourcing approach and dataset for nucleus classification and segmentation in breast cancer. GigaScience. 2022;11:giac037. Enlace.

[4] Sánchez-Torres AL, et al. A Comparative Analysis of Machine Learning and Deep Learning Approaches for Multiclass Nucleus Classification in Histological Images. Applied Computational Intelligence and Soft Computing. 2026;4540418. Enlace.

[5] SENUCLS. Structure Embedded Nucleus Classification for Histopathology Images. Implementación oficial; consulta 06/11/2026. Enlace.

[6] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. Preprint de arquitectura, 2015. arXiv:1512.03385. Enlace.

[7] Sandler M, et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks. Preprint de arquitectura, 2018. arXiv:1801.04381. Enlace.

Conclusión para revisión: existe sustento para investigar clasificación nuclear con DL y usar NuCLS como recurso. La selección definitiva de tres baselines y el cumplimiento integral del estado del arte requieren completar la búsqueda, extracción y frecuencia exigidas.